Problem 3:

子題 1: 出現的次數最多的 DNA 序列

給予一堆相同長度的 ATCG 構成的基因,對測試資料的字串進行分析,對於每一個位置, 找出 ATCG 字符使用最多次的基因,得到一個最優的基因字串,使它滿足與測試資料的基因 字串不同的字元之和最小。如果有多種解,則輸出字典序最小(A,C,G,T)的基因。

T	<u>A</u>	Т	<u>G</u>	<u>A</u>	<u>T</u>	<u>A</u>	<u>C</u>
<u>T</u>	<u>A</u>	<u>A</u>	<u>G</u>	С	<u>T</u>	<u>A</u>	<u>C</u>
A	<u>A</u>	A	<u>G</u>	A	<u>T</u>	С	<u>C</u>
<u>T</u>	G	A	<u>G</u>	A	<u>T</u>	A	<u>C</u>
T	G	<u>A</u>	<u>G</u>	<u>A</u>	<u>T</u>	<u>A</u>	<u>C</u>
T	A	A	G	A	T	A	С

<u>A</u>	<u>C</u>	<mark>G</mark>	<u>T</u>	<u>A</u>	<u>C</u>	<u>G</u>	<u>T</u>	<u>A</u>	<u>C</u>
<u>C</u>	<u>C</u>	<u>G</u>	<u>T</u>	<u>A</u>	<u>C</u>	<u>G</u>	<u>T</u>	<u>A</u>	<u>G</u>
<u>G</u>	<u>C</u>	$\frac{\mathbf{G}}{}$	<u>T</u>	<u>A</u>	<u>C</u>	<u>G</u>	<u>T</u>	<u>A</u>	<u>T</u>
<u>T</u>	<u>C</u>	<u>G</u>	<u>T</u>	A	<u>C</u>	<u>G</u>	<u>T</u>	<u>A</u>	<u>A</u>
<u>A</u>	С	G	Т	A	С	G	T	A	<u>A</u>

第一行 ACGT 和最後一行 CGTA,ATCG 構成的基因, 4 個都出現 1 次,輸出字典序最小 (A,C,G,T)的基因,所以這二行輸出 A。

<u>A</u>	Т	<u>G</u>	<u>T</u>	<u>T</u>	<u>A</u>	<u>C</u>	<u>C</u>	<u>A</u>	<u>T</u>
A	<u>A</u>	<u>G</u>	<u>T</u>	<u>T</u>	<u>A</u>	<u>C</u>	G	<u>A</u>	<u>T</u>
A	<u>A</u>	C	A	A	<u>A</u>	G	<u>C</u>	<u>A</u>	A
<u>A</u>	<u>A</u>	<u>G</u>	<u>T</u>	<u>T</u>	<u>A</u>	<u>C</u>	<u>C</u>	Т	<u>T</u>
A	<u>A</u>	<mark>G</mark>	<u>T</u>	<u>T</u>	<u>A</u>	<u>C</u>	<u>C</u>	<u>A</u>	A
Т	<u>A</u>	C	<u>T</u>	<u>T</u>	<u>A</u>	<u>C</u>	<u>C</u>	<u>A</u>	A
A	A	G	T	T	A	С	C	A	A

最後一行 TTATAA, ATCG 構成的基因, TA2 個都出現 3 次, 輸出字典序最小(A,C,G,T)的基因, 所以這一行輸出 A。

<u>G</u>	<u>A</u>	<u>G</u>	<u>C</u>	<u>A</u>	<u>C</u>	<u>G</u>	<u>T</u>	<u>C</u>
C	<u>A</u>	<u>T</u>	<u>C</u>	<u>A</u>	<u>C</u>	<u>G</u>	<u>T</u>	<mark>G</mark>
G	<u>C</u>	<u>T</u>	<u>T</u>	<u>A</u>	<u>C</u>	<u>G</u>	<u>T</u>	<u>T</u>
C	<u>C</u>	<u>G</u>	<u>T</u>	<u>A</u>	Т	<u>G</u>	<u>T</u>	<u>A</u>
<u>C</u>	<u>A</u>	<u>G</u>	<u>C</u>	A	С	G	T	<u>A</u>

第一行 GCGC、第二行 AACC、第三行 GTTG 和第四行 CCTT,ATCG 構成的基因,各出現 2 次,輸出字典序最小(A,C,G,T)的基因,所以這四行輸出分別為 CAGC。最後一行 CGTA,ATCG 構成的基因, 4 個都出現 1 次,輸出字典序最小(A,C,G,T)的基因,所以這一行輸出

$A \circ$

輸入說明:

第一列的數字 n 代表有幾筆資料要測試, $2 \le n \le 20$,之後為每組的測試資料,每組的測試資料,第一列的二個數字 A B , $4 \le A$, $B \le 50$,以一個或多個空白作為區隔。之後有 A 個長度為 B 的 DNA 序列,直接統計每位四個字母出現的次數,找到出現最多的就是解。如果個數相同取字典序小(A,C,G,T)的基因。

輸出說明:

每筆測試資料輸出一列。出現的次數最多的 DNA 序列,長度為 B 的 DNA 序列。

輸入檔案 1:【檔名: in1.txt】

2

58

TATGATAC

TAAGCTAC

AAAGATCC

TGAGATAC

TGAGATAC

4 10

ACGTACGTAC

CCGTACGTAG

GCGTACGTAT

TCGTACGTAA

輸入檔案 2:【檔名:in2.txt】

2

6 10

ATGTTACCAT

AAGTTACGAT

AACAAAGCAA

AAGTTACCTT

AAGTTACCAA

TACTTACCAA

49

GAGCACGTC

CATCACGTG

GCTTACGTT

CCGTATGTA

輸出範例:【檔名:outl.txt】

TAAGATAC

ACGTACGTAA

輸出範例:【檔名:out2.txt】

AAGTTACCAA CAGCACGTA

資料來源: Uva1368